

[Номер ЗНО С-1101243] Отчет по валидации

Отчет о валидации

Название инициативы/проекта: Автоматический ИИ-ревьюер pull request'ов для локального Azure DevOps Server на базе локальной LLM

Блок инициатора валидации: Информация отсутствует

Отчёт о валидации подготовил: Непочатых Сергей Михайлович

Дата подготовки: 2026-09-14

Итоговая оценка

Соответствие решения DS критериям проверки: Нет
Уровень проверки решения: MVP
Выполнение всех критических критериев: Да
Процент выполненных критериев: 35% (6/17)
Порог выполнения критериев: 75%
Итоговый результат: Требуется значительная доработка
Соответствие бизнес-требованиям: Да
Соответствие техническим метрикам: Нет

Соответствие бизнес-требованиям и заключение по метрикам

Соответствие бизнес-требованиям: Нет

Обоснование: Решение соответствует бизнес требованиям, так как реализована основная бизнес-логика, необходимая для достижения поставленной цели. Однако метрики не указаны в коде и отсутствуют данные о точности формирования построчных замечаний.

Заключение по метрикам:

Анализ корректности выбора метрики
В проекте 'Автоматический ИИ-ревьюер pull request'ов для локального Azure DevOps Server на базе локальной LLM', основной метрикой успешности является точность вердиктов (approve / request_changes / comment) и построчных замечаний, которая должна быть не менее 80%. Эта метрика подходит для оценки качества работы ИИ-ревьюера, так как она напрямую связана с основной задачей проекта - автоматизацией процесса ревью кода. Однако стоит отметить, что эта метрика имеет свои ограничения: она не учитывает качество самих комментариев и замечаний, а также то, насколько полезны эти замечания для разработчиков. В дополнение к точности можно рассмотреть метрики, такие как F1-score или Precision-Recall Curve, которые могут дать более детализированное представление о производительности модели.

Анализ качества метрики
Точность в данном проекте составляет не менее 80%. Это значение указывает на высокую вероятность того, что модель будет принимать правильные решения по большинству случаев. Однако стоит учитывать, что точность может быть искажена, если классы в данных несбалансированы (например, если одобряемые PR значительно превосходят количество требующих изменений). В таком случае высокая точность может быть достигнута за счет преобладания одного из классов. Интерпретация метрики с точки зрения предметной области показывает, что модель должна быть способна заменить ручное ревью в большинстве случаев, обеспечивая при этом качество и полезность комментариев.

Рекомендации
Для улучшения качества модели рекомендуется провести анализ несбалансированности классов. Если обнаружена значительная несбалансированность, следует применить методы балансировки данных (например, oversampling или undersampling). Также можно рассмотреть использование метрик Precision и Recall для более детального понимания производительности модели в различных сценариях. Кроме того, важно регулярно проверять качество комментариев и замечаний, чтобы убедиться, что они полезны для разработчиков.

План мероприятий по устнению ошибок

№	Ошибка / предложение по оптимизации	Раздел	AS IS	TO BE	Приоритет
---	-------------------------------------	--------	-------	-------	-----------

1	Реализованное решение не соответствует заявленной бизнес-задаче. В документах отсутствуют описания бизнес-задачи, ожидаемого результата использования решения, критерии приёмки и целевые метрики.	Целеполагание и оценка	Отсутствует описание бизнес-задачи и ожидаемый результат использования решения. Не формализованы критерии приёмки и целевые метрики.	Добавьте в документацию описание бизнес-задачи и ожидаемый результат использования решения. Формализуйте критерии приёмки и целевые метрики.	
2	Метрики не определены, так как в предоставленном коде или документации отсутствуют упоминания о метриках качества и эффективности решения. В тексте нет информации о выбранных метриках, их целевых значениях или обосновании выбора.	Целеполагание и оценка	Метрики не определены.	Добавить описание метрик в документацию проекта и указать целевые значения для них. Обосновать выбор метрик и согласовать их с заинтересованными сторонами.	
3	В проекте отсутствуют автотесты, что соответствует оценке зего по шкале оценивания.	Код и разработка	Автотестов нет.	Добавить автотесты для критичной бизнес-логики и настроить CI-конфигурацию для автоматического запуска тестов.	
4	В проекте отсутствует файл README или аналогичная документация. Также нет инструкций по запуску решения, описания зависимостей и их установки.	Код и разработка	Инструкции нет.	Создайте файл README с базовыми инструкциями по запуску проекта и добавьте описание необходимых зависимостей.	
5	В коде отсутствуют трассе-логи. Не реализованы логирование промптов и ответов модели, метрики latency, количество токенов и end-to-end трейсинг.	Логика решения	Трассе-логов нет.	Добавить логирование ключевых этапов обработки запросов, включая промпты, ответы модели и метрики. Интегрировать системы трейсинга для получения полных end-to-end traces.	
6	В предоставленном коде отсутствуют тестовые кейсы, golden dataset или eval-датасеты с эталонными ответами. Это означает полное отсутствие набора кейсов для проверки решения.	Качество и эксплуатация	Набора кейсов нет.	Создайте несколько ручных тестовых кейсов и оформите их в структурированном виде файл, таблица, датасет.	
7	Качество модели не проверено или неудовлетворительно. В предоставленном контексте отсутствуют результаты прогона тестовых кейсов, метрики оценки качества моделей и анализ неудачных или низкосортных кейсов.	Качество и эксплуатация	Качество не проверено или неудовлетворительно.	Необходимо провести прогон тестовых кейсов и задокументировать результаты. Также рекомендуется добавить анализ неудачных или проблемных кейсов для улучшения качества модели.	
8	В предоставленном контексте отсутствует любая информация о мониторинге качества ответов модели, метриках latency и cost, а также о порогах и алертах. Это означает, что ни один из критериев прохождения не выполнен.	Качество и эксплуатация	Ничего не отслеживается.	Внедрить систему мониторинга для отслеживания качества ответов модели, метрик latency и cost, а также настроить пороги и уведомления о выходе за эти пороги.	
9	Ошибки по линтерам	Код и разработка	В проекте обнаружено множество предупреждений линтера, связанных с форматированием кода и отсутствием документации.	После исправлений код будет соответствовать стандартам PEP8, иметь четкую структуру импортов и содержать необходимую документацию для всех публичных классов, методов и функций.	

Сводная таблица оценок

Тип	Категория	Критерий	Обязательность	Критичность	Оценка	Обоснование
Базовые правила	Целеполагание и оценка	Соответствие бизнес-требованиям и критериям приёмки	1	1	Без оценки	Реализованное решение не соответствует заявленной бизнес-задаче. В документах отсутствуют описания бизнес-задачи, ожидаемого результата использования решения, критерии приёмки и целевые метрики.
Базовые правила	Целеполагание и оценка	Обоснование выбранного подхода, baseline и архитектуры	1	1	Уровень прототипа	Выбор подхода обоснован с учётом типа задачи, данных и основных ограничений. Рассмотрен хотя бы один альтернативный или более простой подход.

Базовые правила	Целеполагание и оценка	Выбор метрик оценки	1	1	Без оценки	Метрики не определены, так как в предоставленном коде или документации отсутствуют упоминания о метриках качества и эффективности решения. В тексте нет информации о выбранных метриках, их целевых значениях или обосновании выбора.
Базовые правила	Целеполагание и оценка	Тестовый сценарий / набор проверок	1	1	Без оценки	В предоставленном файле отсутствуют любые тестовые сценарии, test cases или чек-листы. Файл содержит только production-код и документацию по архитектуре пайплайна.
Общие для модельных систем	Код и разработка	Покрываемость тестами	1	0	Без оценки	В проекте отсутствуют автотесты, что соответствует оценке zero по шкале оценивания.
Базовые правила	Код и разработка	Инструкция по запуску	1	0	Без оценки	В проекте отсутствует файл README или аналогичная документация. Также нет инструкций по запуску решения, описания зависимостей и их установки.
Базовые правила	Код и разработка	Воспроизводимость запуска	1	1	Уровень прототипа	Решение может быть запущено вручную автором или в знакомом окружении. Однако отсутствуют скрипты или инструкции для запуска решения, что делает его невозможным воспроизвести в других условиях.
Общие для модельных систем	Интеграция и эксплуатация	Подключение источников данных	0	1	Уровень MVP	Код проекта демонстрирует реализацию подключения к внешним источникам данных через REST API с использованием библиотеки requests. Параметры подключения вынесены в конфигурационные файлы, а обработка ошибок и таймауты обеспечивают базовую устойчивость. Однако отсутствует явная реализация retry-логики.
LLM	Входные данные и контекст	Подготовка входных текстов / контекста	1	1	Уровень MVP	В коде реализована базовая очистка входных текстов через функцию _truncate(), которая ограничивает длину текста. Подготовка контекста выполняется автоматизировано для основного сценария, включая нормализацию и форматирование текстов. Контекст собирается из нескольких источников по определенным правилам.
LLM	Качество и эксплуатация	Обработка отказов, галлюцинаций и безопасный fallback	1	1	Уровень MVP	Код реализует базовую обработку исключений при вызове API LLM и предусматривает fallback-сценарии при превышении лимита батчей. Однако отсутствует retry-логика, специфичная обработка ошибок (например, rate limit) и guardrails для фильтрации токсичности или галлюцинаций.
LLM	Логика решения	Trace logging	1	0	Без оценки	В коде отсутствуют trace-логи. Не реализованы логирование промптов и ответов модели, метрики latency, количество токенов и end-to-end трейсинг.
LLM	Качество и эксплуатация	Тестовый набор кейсов	1	0	Без оценки	В предоставленном коде отсутствуют тестовые кейсы, golden dataset или eval-датасеты с эталонными ответами. Это означает полное отсутствие набора кейсов для проверки решения.
LLM	Качество и эксплуатация	Качество на тестовом наборе	1	1	Без оценки	Качество модели не проверено или неудовлетворительно. В предоставленном контексте отсутствуют результаты прогона тестовых кейсов, метрики оценки качества моделей (например, BLEU, ROUGE) и анализ неудачных или низкосортных кейсов.
LLM	Качество и эксплуатация	Мониторинг качества / latency / cost	0	1	Без оценки	В предоставленном контексте отсутствует любая информация о мониторинге качества ответов модели, метриках latency и cost, а также о порогах и алертах. Это означает, что ни один из критериев прохождения не выполнен.

Детальный анализ по критериям

Входные данные и контекст

Подготовка входных текстов / контекста

Критерии оценивания:

Без оценки: Тексты подаются без подготовки.

Уровень прототипа: Есть базовая очистка и ручная подготовка.

Уровень MVP: Подготовка текстов и контекста оформлена для основного сценария.

Уровень продукта: Подготовка системная: очистка, нормализация, разбиение, сборка контекста, правила включения данных.

Оценка: Уровень MVP

Обоснование: В коде реализована базовая очистка входных текстов через функцию `_truncate()`, которая ограничивает длину текста. Подготовка контекста выполняется автоматизировано для основного сценария, включая нормализацию и форматирование текстов. Контекст собирается из нескольких источников по определённым правилам.

Рекомендации: Для достижения оценки product рекомендуется добавить более сложные методы очистки и нормализации текста, такие как regex-очистка и приведение к нижнему регистру. Также можно улучшить логику сборки контекста с учетом приоритетов и ограничений.

Интеграция и эксплуатация

Подключение источников данных

Критерии оценивания:

Без оценки: Используются только локальные файлы или ручные выгрузки.

Уровень прототипа: Основные источники подключены и используются в пайплайне.

Уровень MVP / Уровень продукта: Подключение стандартизовано, стабильно и конфигурируемо.

Оценка: Уровень MVP

Обоснование: Код проекта демонстрирует реализацию подключения к внешним источникам данных через REST API с использованием библиотеки `requests`. Параметры подключения вынесены в конфигурационные файлы, а обработка ошибок и таймауты обеспечивают базовую устойчивость. Однако отсутствует явная реализация `retry`-логики.

Рекомендации: Добавьте явную реализацию `retry`-логики для повышения устойчивости подключения.

Качество и эксплуатация

Обработка отказов, галлюцинаций и безопасный fallback

Критерии оценивания:

Без оценки: Ошибки API и некорректные ответы модели не обрабатываются, падают в `exception`.

Уровень прототипа: Есть базовая обработка ошибок API и таймаутов.

Уровень MVP: Предусмотрены fallback-сценарии и базовые ограничения на генерацию.

Уровень продукта: Есть формальный контур обработки отказов, `guardrails` и эскалации.

Оценка: Уровень MVP

Обоснование: Код реализует базовую обработку исключений при вызове API LLM и предусматривает fallback-сценарии при превышении лимита батчей. Однако отсутствует `retry`-логика, специфичная обработка ошибок (например, `rate limit`) и `guardrails` для фильтрации токсичности или галлюцинаций.

Рекомендации: Добавить `retry`-логику с экспоненциальной задержкой и внедрить проверки на галлюцинации.

Тестовый набор кейсов

Критерии оценивания:

Без оценки: Набора кейсов нет.

Уровень прототипа: Есть несколько ручных кейсов.

Уровень MVP: Есть повторяемый набор `representative`-кейсов.

Уровень продукта: Есть покрытие основных и пограничных кейсов с ожидаемыми результатами.

Оценка: Без оценки

Обоснование: В предоставленном коде отсутствуют тестовые кейсы, `golden dataset` или `eval`-датасеты с эталонными ответами. Это означает полное отсутствие набора кейсов для проверки решения.

Рекомендации: Создайте несколько ручных тестовых кейсов и оформите их в структурированном виде (файл, таблица, датасет).

Качество на тестовом наборе

Критерии оценивания:

Без оценки: Качество не проверено или неудовлетворительно.

Уровень прототипа: Основной сценарий частично работает.

Уровень MVP: Основные кейсы проходят на приемлемом уровне.

Уровень продукта: Качество стабильно на основных и пограничных кейсах.

Оценка: Без оценки

Обоснование: Качество модели не проверено или неудовлетворительно. В предоставленном контексте отсутствуют результаты прогона тестовых кейсов, метрики оценки качества моделей (например, BLEU, ROUGE) и анализ неудачных или низкокачественных кейсов.

Рекомендации: Необходимо провести прогон тестовых кейсов и задокументировать результаты. Также рекомендуется добавить анализ неудачных или проблемных кейсов для улучшения качества модели.

Мониторинг качества / latency / cost

Критерии оценивания:

Без оценки: Ничего не отслеживается.

Уровень прототипа / Уровень MVP / Уровень продукта: Есть системный мониторинг качества, latency и cost с порогами и реакцией на отклонения.

Оценка: Без оценки

Обоснование: В предоставленном контексте отсутствует любая информация о мониторинге качества ответов модели, метриках latency и cost, а также о порогах и алертах. Это означает, что ни один из критериев прохождения не выполнен.

Рекомендации: Внедрить систему мониторинга для отслеживания качества ответов модели, метрик latency и cost, а также настроить пороги и уведомления о выходе за эти пороги.

Код и разработка

Покрытие тестами

Критерии оценивания:

Без оценки: Автотестов нет.

Уровень прототипа: Есть автотесты для критичной логики.

Уровень MVP / Уровень продукта: Покрыты основные и регрессионные сценарии; ориентир по покрытию — не менее 20%.

Оценка: Без оценки

Обоснование: В проекте отсутствуют автотесты, что соответствует оценке zero по шкале оценивания.

Рекомендации: Добавить автотесты для критичной бизнес-логики и настроить CI-конфигурацию для автоматического запуска тестов.

Инструкция по запуску

Критерии оценивания:

Без оценки: Инструкции нет.

Уровень прототипа: Есть минимальная инструкция для автора или команды.

Уровень MVP: По инструкции решение может запустить другой человек.

Уровень продукта: Есть полная инструкция запуска, конфигурации, типовые ошибки и сопровождение.

Оценка: Без оценки

Обоснование: В проекте отсутствует файл README или аналогичная документация. Также нет инструкций по запуску решения, описания зависимостей и их установки.

Рекомендации: Создайте файл README с базовыми инструкциями по запуску проекта и добавьте описание необходимых зависимостей.

Воспроизводимость запуска

Критерии оценивания:

Без оценки: Запуск нестабилен и зависит от автора.

Уровень прототипа: Решение запускается вручную в ограниченном окружении.

Уровень MVP: Запуск воспроизводим в тестовом контуре или у другого участника команды.

Уровень продукта: Запуск стандартизован и воспроизводим в целевом окружении.

Оценка: Уровень прототипа

Обоснование: Решение может быть запущено вручную автором или в знакомом окружении. Однако отсутствуют скрипты или инструкции для запуска решения, что делает его невозможным воспроизвести в других условиях.

Рекомендации: Добавьте скрипт или инструкцию для запуска решения и зафиксируйте зависимости в requirements.txt или аналогичном файле.

Логика решения

Trace logging

Критерии оценивания:

Без оценки: Трасс-логов нет.

Уровень прототипа: Логируются ключевые этапы: prompt/version, latency, tokens, context.

Уровень MVP / Уровень продукта: Есть полные end-to-end traces для анализа и отладки.

Оценка: Без оценки

Обоснование: В коде отсутствуют trace-логи. Не реализованы логирование промптов и ответов модели, метрики latency, количество токенов и end-to-end трейсинг.

Рекомендации: Добавить логирование ключевых этапов обработки запросов, включая промпты, ответы модели и метрики. Интегрировать системы трейсинга для получения полных end-to-end traces.

Целеполагание и оценка

Соответствие бизнес-требованиям и критериям приёмки

Критерии оценивания:

Без оценки: Реализованное решение не соответствует заявленной бизнес-задаче либо соответствие невозможно проверить. Технические метрики не сопоставлены с бизнес-требованиями.

Уровень прототипа: Основной бизнес-сценарий реализован. Фактический результат сопоставлен с требованиями и критериями успешности, а невыполненные требования явно указаны.

Уровень MVP: Сформирована связь между бизнес-требованиями, реализованной функциональностью, техническими метриками и результатами проверки. Соответствие подтверждено для основных сценариев и сегментов.

Уровень продукта: Бизнес-требования и критерии приёмки формализованы, согласованы и используются при выпуске решения, мониторинге и принятии решений об изменениях.

Оценка: Без оценки

Обоснование: Реализованное решение не соответствует заявленной бизнес-задаче. В документах отсутствуют описания бизнес-задачи, ожидаемого результата использования решения, критерии приёмки и целевые метрики.

Рекомендации: Добавьте в документацию описание бизнес-задачи и ожидаемый результат использования решения. Формализуйте критерии приёмки и целевые метрики.

Обоснование выбранного подхода, baseline и архитектуры

Критерии оценивания:

Без оценки: Метод решения, модель или архитектура выбраны без объяснения. Альтернативные и более простые подходы не рассмотрены, baseline отсутствует без обоснования.

Уровень прототипа: Выбор подхода обоснован с учётом типа задачи, данных и основных ограничений. Рассмотрено хотя бы одно альтернативное или более простое решение, определён baseline, если он применим.

Уровень MVP: Несколько подходов или конфигураций сопоставлены на единой схеме проверки. Выбор подтверждён качеством, устойчивостью и эксплуатационными ограничениями.

Уровень продукта: Архитектура обоснована совокупностью качества, стоимости, производительности, рисков и сопровождаемости. Причины отказа от значимых альтернатив зафиксированы.

Оценка: Уровень прототипа

Обоснование: Выбор подхода обоснован с учётом типа задачи, данных и основных ограничений. Рассмотрен хотя бы один альтернативный или более простой подход.

Рекомендации: Добавьте описание baseline-модели или эвристики для сравнения. Укажите причины выбора LLM-ревью над другими методами.

Выбор метрик оценки

Критерии оценивания:

Без оценки: Метрики не определены.

Уровень прототипа: Метрики выбраны и в целом соответствуют задаче.

Уровень MVP: Метрики выбраны корректно и для них есть целевые значения.

Уровень продукта: Метрики обоснованы, согласованы и используются как критерий приёмки.

Оценка: Без оценки

Обоснование: Метрики не определены, так как в предоставленном коде или документации отсутствуют упоминания о метриках качества и эффективности решения. В тексте нет информации о выбранных метриках, их целевых значениях или обосновании выбора.

Рекомендации: Добавить описание метрик в документацию проекта и указать целевые значения для них. Обосновать выбор метрик и согласовать их с заинтересованными сторонами.

Тестовый сценарий / набор проверок

Критерии оценивания:

Без оценки: Повторяемый способ проверки отсутствует.

Уровень прототипа: Есть ручной повторяемый сценарий проверки основного кейса.

Уровень MVP: Есть оформленный набор кейсов для проверки основных сценариев.

Уровень продукта: Есть полный набор основных и пограничных кейсов с ожидаемыми результатами.

Оценка: Без оценки

Обоснование: В предоставленном файле отсутствуют любые тестовые сценарии, test cases или чек-листы. Файл содержит только production-код и документацию по архитектуре пайплайна.

Рекомендации: Добавьте описание хотя бы одного ручного сценария проверки основного функционала с последовательностью шагов для воспроизведения проверки.

Заключение по линтерам

Качество кода:

- Лишние пробелы в конце строки. Удалите лишние пробелы в конце строк комментариев. Примеры: # Автоматическое ревью pull request'ов в Azure DevOps Server ## **Автор**: auto_git_review (Rail-Akhm) , # **Стек**: Python 3.10+ · Apache Airflow · Azure DevOps Server (on-prem) · LiteLLM / qwen3 # # --- , # --- # # ## Цель
- Слишком длинные строки. Разбейте длинные строки на несколько более коротких. Примеры: # | Полный текст одного файла в промпте | $\leq$ `MAX\_CHANGE\_CHARS = 12000` симв. (модель видит весь файл, а не фрагменты diff) | , # | **H1** | Проверка dedup-маркера по тексту (а не по автору) до вызова LLM гарантирует отсутствие повторного ревью и не трогает комментарии реального пользователя | Раздел 4 | , # | **H2** | Батчевание держит каждый вызов LLM в лимите контекста; обрезка `MAX\_CHANGE\_CHARS` / `MAX\_DIFF\_CHARS` защищает от переполнения | Раздел 5 |
- Импорты модулей не находятся в начале файла. Переместите все импорты в начало файла. Примеры: import os from dataclasses import dataclass , import urllib3
- Отсутствуют docstring для публичных классов. Добавьте описание для каждого публичного класса. Примеры: @dataclass(frozen=True) class Settings: azure_url: str , class AlmClient: def __init__(self, settings=None): , class LlmClient: def __init__(self, settings=None):
- Отсутствуют docstring для публичных функций. Добавьте описание для каждой публичной функции. Примеры: def get_settings() -> Settings: return Settings(, # --- Дополнение для ноутбука: помощник для «живых» клеток и маскирование секретов --- def require_live(): missing = [] , def mask(s: str) -> str: return (s[4] + "... " + s[-2:]) if len(s) > 8 else ("*****" if s else "")
- Отсутствуют docstring для публичных методов. Добавьте описание для каждого публичного метода. Примеры: def get_pull_request(self, pr_id: int, repo: str = None) -> dict: repo = repo or self.settings.azure_repo , def get_pr_work_items(self, pr_id: int, repo: str = None) -> dict: repo = repo or self.settings.azure_repo , def get_work_item(self, work_item_id: int) -> dict: # WIT — коллекционный эндпоинт (не привязан к проекту).
- Слишком сложная функция. Разделите функцию на более мелкие части. Примеры: def run_review(log=None, repo: str = None, project: str = None, post_comment: bool = False, prompt_name: str = None, max_batches: int = 20): """Главная функция: ревью всех открытых PR. Подробно логирует каждый шаг."""