

Ответ на замечания по валидации

Проект: auto_git_review — автоматический ИИ-ревьюер pull request'ов для локального Azure DevOps Server на базе локальной LLM.

Документ: ответ на отчёт по валидации [Номер ЗНО С-1101243] от 2026-09-14.

Дата: 2026-09-17.

Общий комментарий

Отчёт подготовлен по усечённой подаче: на валидацию был передан демонстрационный ноутбук (auto_git_review_research.ipynb) с встроенным production-кодом, но без файла README.md , который в репозитории присутствует и содержит цель, архитектуру, структуру проекта и инструкцию по запуску. Это привело к тому, что часть критериев (в первую очередь «Инструкция по запуску» и «Соответствие бизнес-требованиям») оценены как «Без оценки», хотя соответствующие материалы существуют.

Ниже — закрытие каждого замечания по пунктам с указанием, что именно изменено и где смотреть.

Замечание 1. Не описана бизнес-задача, ожидаемый результат, критерии приёмки и целевые метрики

Приоритет: Высокий.

Статус: исправлено.

Что сделано: в README.md добавлены разделы «Цель и ожидаемый результат» и «Критерии приёмки», формализующие бизнес-задачу, ожидаемый результат использования решения и критерии, по которым решение считается выполненным.

Замечание 2. Метрики не определены

Приоритет: Высокий.

Статус: исправлено (декларация) / в работе (подтверждение прогоном).

Что сделано: в README.md добавлен раздел «Метрики качества» с целевыми значениями и обоснованием выбора.

Замечание 3. Отсутствуют автотесты

Приоритет: Высокий.

Статус: исправлено.

Что сделано: добавлен набор unit-тестов на чистую логику пайплайна — tests/ (41 тест, все проходят):

- test_review.py — агрегация вердиктов по батчам, dedup-маркер, лимит батчей;
- test_prompt.py — загрузка и рендеринг промптов ([[WORK_ITEM]] , [[FILES]]);

- `test_config.py` — чтение настроек из env и их дефолты;
- `test_alm.py` — сборка URL коллекции/проекта, разбор ответов REST API;
- `test_llm.py` — разбор ответа LLM, учёт usage и latency;
- `test_eval.py` — расчёт accuracy / Precision / Recall / F1, confusion matrix;
- `test_monitoring.py` — агрегация сводных метрик прогона.

Конфигурация: `pytest.ini` (`pythonpath = loader/src`), зависимости разработки — `requirements-dev.txt` (`pytest` , `ruff`). Запуск: `pytest` .

Замечание 4. Отсутствует README и инструкции по запуску

Приоритет: Высокий.

Статус: исправлено (материал существовал, но не был включён в подачу).

Что сделано: `README.md` присутствует в репозитории; в него добавлены инструкции по установке зависимостей и запуску. Раздел «Запуск в Airflow» существовал ранее.

Замечание 5. Отсутствуют trace-логи (промты, ответы, latency, токены, end-to-end)

Приоритет: Высокий.

Статус: исправлено.

Что сделано:

- `llm.py` — `chat()` теперь возвращает словарь `{content, reasoning, usage, latency_ms}` ; логирует промпт и ответ на уровне DEBUG, а на уровне INFO — строку `LLM ответ: latency=...ms, tokens=...` с разобранным `usage` (prompt / completion / total);
 - `review.py` — замер end-to-end латентности на каждый PR (`latency_ms`) и накопление токенов (`tokens`) по всем вызовам LLM в рамках PR; результат каждого PR несёт `pr_id` , `verdict` , `latency_ms` , `tokens` ;
 - `monitoring.py` — `emit_summary()` логирует итоговую сводку прогона одной структурированной JSON-строкой `REVIEW_RUN_METRICS {...}` (итог по вердиктам, суммарная латентность, суммарные токены, оценка стоимости).
-

Замечание 6. Отсутствуют тестовые кейсы / golden dataset / eval-датасет

Приоритет: Высокий.

Статус: исправлено (инфраструктура) / в работе (наполнение реальными данными).

Что сделано:

- `eval.py` — модуль оценки: `load_dataset()` (формат `{"cases": [...]}`), `compute_metrics()` (accuracy, Precision / Recall / F1 по каждому классу, confusion matrix), `evaluate()` , `format_report()` и `write_report()` ;
- `tests/eval/golden_dataset.example.json` — пример датасета с эталонными вердиктами (`verdict_expected`) и полем `source` (3 кейса: approve, request_changes, comment) — задаёт схему

для наполнения.

Наполнение реальными PR-кейсами и эталонными вердиктами эксперта выполняется в корпоративном контуре (нужны реальные PR и экспертные вердикты).

Замечание 7. Качество модели не проверено

Приоритет: Высокий.

Статус: в работе (прогон в корпоративном контуре).

Что сделано: заложен механизм прогона eval — `eval.py` реализует `evaluate(reviewer, dataset)`, где `reviewer` — подключаемый callable, возвращающий вердикт модели по кейсу; рассчитываются accuracy, Precision / Recall / F1 по каждому классу (`approve` / `request_changes` / `comment`) и confusion matrix, формируется markdown-отчёт (`write_report`). Метрики привязаны к целевым значениям из `README.md` (accuracy ≥ 80%, Precision / Recall ≥ 0.7).

Живой прогон с моделью и датасетом требует доступа к ALM/LLM в корпоративном контуре — выполняется после наполнения golden set (замечание 6).

Замечание 8. Отсутствует мониторинг качества / latency / cost

Приоритет: Высокий.

Статус: исправлено (инфраструктура) / в работе (пороги и алерты).

Что сделано: `monitoring.py` — `summarize()` агрегирует результаты PR в сводные метрики (количество PR, распределение по вердиктам, суммарная латентность, суммарные токены, оценка стоимости `COST_PER_1K_TOKENS`); `emit_summary()` пишет сводку одной JSON-строкой `REVIEW_RUN_METRICS {...}`, пригодной для разбора ELK / Prometheus-экспортером. Вызов `emit_summary` встроен в конец `review.run_review()`.

Настройка порогов и алертов по этим метрикам — на стороне эксплуатации в корпоративном контуре (требуется реальный прогон для калибровки порогов).

Замечание 9. Ошибки по линтерам (PEP8, импорты, docstring)

Приоритет: Низкий.

Статус: исправлено.

Что сделано: добавлены docstring публичных классов/функций, исправлен порядок импортов, убраны хвостовые пробелы и длинные строки.

Сводная таблица закрытия

№	Замечание	Статус
1	Бизнес-задача и критерии приёмки	✓ Исправлено
2	Метрики не определены	✓ Декларированы /  подтверждение прогоном
3	Автотесты	✓ Исправлено (41 тест)
4	README и инструкции	✓ Исправлено
5	Trace-логи (промпт, ответ, latency, токены)	✓ Исправлено
6	Тестовые кейсы / eval-датасет	✓ Инфраструктура /  наполнение данными
7	Качество модели	✓ Механизм оценки /  прогон в контуре
8	Мониторинг (latency / cost / качество)	✓ Инфраструктура /  пороги и алерты
9	Линтер (PEP8, импорты, docstring)	✓ Исправлено